Classification du Cancer du Sein

Projet Machine Learning

Dataset : Breast Cancer Wisconsin — Kaggle / UCI

569 patients • 30 features • 2 classes (Bénin / Malin)

EDA → Modélisation → Déploiement Streamlit

Breast Cancer Wisconsin (Kaggle / UCI)

569
Patients
455 train • 114 test

33→31
Colonnes
id + Unnamed:32 supprimées

0
Valeurs manquantes
Dataset propre

M:212 B:357
Distribution cible
M=Malin B=Bénin

Features (30 variables numériques)

Mean (10)

radius, texture, perimeter, area, smoothness, compactness, concavity, concave_points, symmetry, fractal_dimension

SE (10)

Mêmes 10 features — erreur standard

Worst (10)

Mêmes 10 features — valeur la plus sévère

Encodage cible : M → 1 • B → 0 • Séparation train/test stratifiée (random_state=42)

6 visualisations — résultats clés

Matrice de Corrélation

Heatmap (coolwarm, 31×31)
Forte corrélation entre les features _mean et _worst → redondance. radius / area / perimeter très liés entre eux.

Top 10 Features vs Diagnostic

concave_points_worst, perimeter_worst, concave_points_mean en tête.
Ces features sont les plus discriminantes pour détecter la malignité.

KDE Distributions

radius_mean, area_mean, concavity_mean : Séparation nette Malin (M=1) / Bénin (B=0). Distributions quasi non-chevauchantes.

Boxplots — Outliers

Outliers détectés sur radius_mean, texture_mean, area_mean.
Conservés car cohérents biologiquement (tumeurs extrêmes réelles).

Pairplot (4 features clés)

radius_mean, texture_mean, area_mean, concavity_mean.
Clusters visuellement séparables selon diagnosis.

PCA 2 composantes

Projection 2D de 30 features normalisées. Séparabilité linéaire confirmée — 2 clusters distincts visibles.

Pipeline d'entraînement — 3 modèles comparés

data_clean.csv (569×31) → StandardScaler fit sur X_train → train_test_split 80% / 20% stratify=y rs=42 → Entraînement 3 modèles → **Évaluation Accuracy + AUC**

Logistic Regression

★ MEILLEUR AUC

Params : max_iter=1000

Accuracy : 96.5% ROC AUC : 0.9960

Classe	Précision	Recall	F1
Bénin	0.96	0.99	0.97
Malin	0.97	0.93	0.95

Modèle sélectionné et sauvegardé (model.pkl)

Random Forest

Params : n_estimators=100, rs=42

Accuracy : 97.4% ROC AUC : 0.9929

Classe	Précision	Recall	F1
Bénin	0.96	1.00	0.98
Malin	1.00	0.93	0.96

Accuracy légèrement sup. mais AUC < LR

SVM (RBF)

Params : kernel='rbf', probability=True, rs=42

Accuracy : 97.4% ROC AUC : 0.9947

Classe	Précision	Recall	F1
Bénin	0.96	1.00	0.98
Malin	1.00	0.93	0.96

AUC proche LR, moins interprétable

Modèle retenu : Logistic Regression (max_iter=1000, StandardScaler)

96.49%
Accuracy
110/114 prédictions correctes

0.9960
ROC AUC
Meilleur des 3 modèles

0.97
F1 Bénin
Précision 0.96 / Recall 0.99

0.95
F1 Malin
Précision 0.97 / Recall 0.93

Matrice de Confusion — Test set (114 patients)

	Prédit Bénin	Prédit Malin
Réel Bénin (72)	**TN = 71**	FP = 1
Réel Malin (42)	FN = 3	**TP = 39**

Comparatif final

Logistic Regression : Accuracy 96.49% • AUC 0.9960

Random Forest : Accuracy 97.37% • AUC 0.9929

SVM (RBF) : Accuracy 97.37% • AUC 0.9947

→ LR sélectionné car AUC le plus élevé (0.9960), plus interprétable et déployable facilement via joblib.

Prédiction interactive via interface web (app.py)

Fonctionnement de l'application

1. **Chargement des données**

   Upload CSV ou saisie manuelle des 30 features via widgets (combobox / sliders ipywidgets)

2. **Normalisation automatique**

   scaler.pkl chargé via joblib — StandardScaler appliqué sur les entrées utilisateur

3. **Prédiction**

   model.pkl (Logistic Regression) — renvoie la classe (Bénin/Malin) + probabilité associée

4. **Visualisations dynamiques**

   Courbe ROC, matrice de confusion, classification_report affichés dans Streamlit

Fichiers sauvegardés (joblib)

model.pkl

Régression Logistique entraînée

scaler.pkl

StandardScaler ajusté sur X_train

columns.pkl

Liste des 30 features (X.columns)

app.py / app_logistic.py

Code Streamlit — interface web complète

Stack : Python • Pandas • NumPy • Scikit-learn • Matplotlib • Seaborn • Streamlit • Joblib • ipywidgets

🩺 NETSAWER PRO · AKTHER

Formulaire de prédiction du cancer du sein (Régression Logistique)

📊 Paramètres principaux (12 features)

texture_worst

25.480 (médiane)

compactness_se

0.020 (médiane)

radius_se

0.327 (médiane)

area_worst

683.400 (médiane)

symmetry_worst

0.282 (médiane)

radius_worst

14.920 (médiane)

concave points_mean

0.033 (médiane)

concavity_mean

0.059 (médiane)

concavity_worst

0.230 (médiane)

perimeter_se

2.310 (médiane)

area_se

24.870 (médiane)

perimeter_worst

97.650 (médiane)

🔍 DIAGNOSTIQUER

Bilan du projet

Conclusion & Résultats

Dataset

Breast Cancer Wisconsin (Kaggle) — 569 patients, 30 features, 0 NaN
Encodage M→1/B→0, suppression id + Unnamed:32

EDA

6 visualisations : corrélations, Top-10 features, KDE, boxplots, pairplot, PCA → séparabilité linéaire confirmée

Modèle retenu

Logistic Regression — Accuracy 96.49% • AUC ROC 0.9960
TN=71 FP=1 FN=3 TP=39 (sur 114 patients test)

Déploiement

App Streamlit (app.py) + formulaire ipywidgets
model.pkl + scaler.pkl + columns.pkl via joblib

Pipeline complet : EDA → Modélisation → Évaluation → Déploiement